

# 数值分析内部课程习题解答

## 第四章第二部分

SCAU DataHub

2025 年 5 月 5 日

### 目录

5	Newton for nonlinear systems	2
6	Quasi-Newton methods	4
7	Nonlinear least squares	5

## 5 Newton for nonlinear systems

**Solution 5.1.** 根据算法 4.5.4 计算.

- 第一步, 计算 Jacobi 矩阵

$$\mathbf{J}(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} x_2 & x_1 + 2x_2 \\ x_2^3 + 2x_1x_2^2 & 3x_1x_2^2 + 2x_1^2x_2 \end{bmatrix},$$

接着代入  $\mathbf{x}_1 = [-2, 1]^T$  计算  $\mathbf{y}_1$  和  $\mathbf{A}_1$

$$\mathbf{y}_1 = \mathbf{f}(\mathbf{x}_1) = \begin{bmatrix} -2 \\ 3 \end{bmatrix}, \quad \mathbf{A}_1 = \mathbf{J}(\mathbf{x}_1) = \begin{bmatrix} 1 & 0 \\ -3 & 2 \end{bmatrix}.$$

- 第二步, 求解线性方程组  $\mathbf{A}_1\mathbf{s}_1 = -\mathbf{y}_1$ , 得到  $\mathbf{s}_1 = [2, \frac{3}{2}]^T$ .
- 第三步,  $\mathbf{x}_2 = \mathbf{x}_1 + \mathbf{s}_1 = [0, \frac{5}{2}]^T$ .

**Solution 5.2.** 根据多维的牛顿迭代算法, 代入题设  $\mathbf{f}(\mathbf{x}) = \mathbf{Ax} - \mathbf{b}$  可证, 过程略.

**Solution 5.3.** 学会构造方程组并通过算法求根.

(a) 非线性系统为

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} u \ln u + v \ln v + 0.3 \\ u^4 + v^2 - 1 \end{bmatrix} = \mathbf{0}, \quad \mathbf{x} = \begin{bmatrix} u \\ v \end{bmatrix}.$$

(b) Jacobi 矩阵为

$$\mathbf{J}(\mathbf{x}) = \begin{bmatrix} \ln u + 1 & \ln v + 1 \\ 4u^3 & 2v \end{bmatrix}.$$

(c) 代码见 Gitee 仓库.

(d) 代码见 Gitee 仓库.

**Solution 5.4.** 学会构造方程组并通过算法求根.

(a) 代码见 Gitee 仓库.

(b) 考虑将参数方程化为关于  $x, y$  的方程, 由题设

$$x_1(t) = -5 + 10 \cos(t), \quad y_1(t) = 6 \sin(t),$$

将右边挪剩  $\cos(t)$  和  $\sin(t)$

$$(x_1(t) + 5)/10 = \cos(t), \quad y_1(t)/6 = \sin(t),$$

利用  $\cos^2(t) + \sin^2(t) = 1$ , 得到

$$\left(\frac{x_1 + 5}{10}\right)^2 + \left(\frac{y_1}{6}\right)^2 = 1.$$

同理得第二个椭圆方程

$$\left(\frac{x_2}{8}\right)^2 + \left(\frac{y_2 - 3}{12}\right)^2 = 1.$$

于是非线性系统为

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} \left(\frac{x+5}{10}\right)^2 + \left(\frac{y}{6}\right)^2 - 1 \\ \left(\frac{x}{8}\right)^2 + \left(\frac{y-3}{12}\right)^2 - 1 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

(c) Jacobi 矩阵为

$$\mathbf{J}(\mathbf{x}) = \begin{bmatrix} \frac{x+5}{50} & \frac{y}{18} \\ \frac{x}{32} & \frac{y-3}{72} \end{bmatrix}.$$

(d) 代码见 Gitee 仓库.

**Solution 5.5.** 反复试错为牛顿法寻找合适的初值.

(a) 非线性系统为

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} x - 5 - \frac{\lambda x}{25} \\ y - 4 - \frac{\lambda y}{16} \\ z - 3 - \frac{\lambda z}{9} \\ \frac{x^2}{25} + \frac{y^2}{16} + \frac{z^2}{9} - 1 \end{bmatrix} = \mathbf{0}.$$

(b) Jacobi 矩阵为

$$J(u) = \begin{bmatrix} 1 - \frac{\lambda}{25} & 0 & 0 & -\frac{x}{25} \\ 0 & 1 - \frac{\lambda}{16} & 0 & -\frac{y}{16} \\ 0 & 0 & 1 - \frac{\lambda}{9} & -\frac{z}{9} \\ \frac{2x}{25} & \frac{2y}{16} & \frac{2z}{9} & 0 \end{bmatrix}.$$

(c) 代码见 Gitee 仓库.

**Solution 5.6.** 代码见 Gitee 仓库.

## 6 Quasi-Newton methods

**Solution 6.1.** 代码见 Gitee 仓库.

**Solution 6.2.** 代码见 Gitee 仓库.

**Solution 6.3.** 代码见 Gitee 仓库.

**Solution 6.4.** 这是一个验证性的证明.

不妨先简化记号, 设

$$\mathbf{B} = \mathbf{A} + \mathbf{u}\mathbf{v}^T, \quad \mathbf{C} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta}, \quad \beta = 1 + \mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}.$$

我们希望证明  $\mathbf{C} = \mathbf{B}^{-1}$ , 即  $\mathbf{BC} = \mathbf{I}$  且  $\mathbf{CB} = \mathbf{I}$ .

我们演示计算  $\mathbf{BC}$  的过程

$$\begin{aligned} \mathbf{BC} &= (\mathbf{A} + \mathbf{u}\mathbf{v}^T) \left( \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta} \right) \\ &= \underbrace{\mathbf{A}\mathbf{A}^{-1}}_{=\mathbf{I}} - \frac{\mathbf{A}\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta} + \mathbf{u}\mathbf{v}^T\mathbf{A}^{-1} - \frac{\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta} \\ &= \mathbf{I} - \frac{\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta} + \mathbf{u}\mathbf{v}^T\mathbf{A}^{-1} - \frac{\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta} \end{aligned}$$

注意到  $\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}$  是标量, 于是

$$\frac{\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta} = \frac{(\mathbf{u}(\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}))\mathbf{v}^T\mathbf{A}^{-1}}{\beta} = (\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}) \frac{\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}{\beta}.$$

我们将所有  $\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}$  项合并, 可得

$$\begin{aligned} \mathbf{BC} &= \mathbf{I} - \frac{1}{\beta}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1} + \mathbf{u}\mathbf{v}^T\mathbf{A}^{-1} - \frac{\mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}}{\beta}(\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}) \\ &= \mathbf{I} - \underbrace{\frac{1 - \beta + \mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}}{\beta}\mathbf{u}\mathbf{v}^T\mathbf{A}^{-1}}_{=0}, \end{aligned}$$

只需要代入记号  $\beta$  的表达式, 就可以发现第二项为  $\mathbf{0}$ , 进而证明  $\mathbf{BC} = \mathbf{I}$ .

计算右乘也同理, 可算出  $\mathbf{CB} = \mathbf{I}$ , 步骤一模一样, 只是展开顺序互换.

因此, 只要  $\mathbf{A}$  可逆且  $\beta \neq 0$ , 就有

$$(\mathbf{A} + \mathbf{u}\mathbf{v}^T)^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \frac{\mathbf{u}\mathbf{v}^T}{1 + \mathbf{v}^T\mathbf{A}^{-1}\mathbf{u}} \mathbf{A}^{-1}$$

**Solution 6.5.** 这是多元函数微分, 关键是把向量形式用分量具体写出来.

根据教材记号

$$\mathbf{f} = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x}) \end{bmatrix}, \quad \mathbf{J}(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}.$$

我们将  $\varphi(\mathbf{x})$  写成分量的形式

$$\varphi(\mathbf{x}) = \mathbf{f}(\mathbf{x})^T \mathbf{f}(\mathbf{x}) = \sum_{i=1}^n f_i(\mathbf{x})^2.$$

对第  $x_j$  个分量求偏导:

$$\frac{\partial \varphi}{\partial x_j} = \sum_{i=1}^n 2 f_i(\mathbf{x}) \frac{\partial f_i}{\partial x_j} = 2 \underbrace{\begin{bmatrix} \frac{\partial f_1}{\partial x_j} \\ \frac{\partial f_2}{\partial x_j} \\ \vdots \\ \frac{\partial f_n}{\partial x_j} \end{bmatrix}^T \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x}) \end{bmatrix}}_{\text{将求和写成内积的形式}} = 2 [\mathbf{J}(\mathbf{x})^T \mathbf{f}(\mathbf{x})]_j.$$

把所有  $n$  个偏导量收集成向量使得

$$\nabla \varphi(\mathbf{x}) = 2 \mathbf{J}(\mathbf{x})^T \mathbf{f}(\mathbf{x}).$$

注:  $\nabla$  表示梯度, 一元函数求导叫导数, 多元函数对一个元求导叫偏导, 多元函数对所有元求导叫梯度.

**Solution 6.6.** Levenberg 方法等价于 Newton 法加惩罚项.

将题设优化问题通过矩阵分块写为最小二乘的形式

$$\min_{\mathbf{v}} \left\| \begin{bmatrix} \mathbf{A}_k \\ \lambda \mathbf{I} \end{bmatrix} \mathbf{v} + \begin{bmatrix} \mathbf{f}_k \\ \mathbf{0} \end{bmatrix} \right\|_2^2,$$

并记

$$\mathbf{M} = \begin{bmatrix} \mathbf{A}_k \\ \lambda \mathbf{I} \end{bmatrix}, \quad \mathbf{c} = \begin{bmatrix} \mathbf{f}_k \\ \mathbf{0} \end{bmatrix},$$

那么就变为最小二乘的形式, 即  $\min_{\mathbf{v}} \|\mathbf{M}\mathbf{v} + \mathbf{c}\|_2^2$ , 其正规方程为

$$\mathbf{M}^T \mathbf{M} \mathbf{v} = -\mathbf{M}^T \mathbf{c}.$$

直接计算, 有

$$\mathbf{M}^T \mathbf{M} = \mathbf{A}_k^T \mathbf{A}_k + \lambda^2 \mathbf{I}, \quad \mathbf{M}^T \mathbf{c} = \mathbf{A}_k^T \mathbf{f}_k,$$

所以 Levenberg 方法就是上述最小二乘问题的正规方程, 二者同解.

## 7 Nonlinear least squares

**Solution 7.1.** 将非线性函数用线性近似, 并求线性近似意义下的解.

- (a) 对非线性向量函数  $\mathbf{f}(x) = [x - 8, x^2 - 4]$ , 其在某点  $x$  附近的线性近似 (一阶泰勒近似) 为

$$\mathbf{q}(x + s) = \mathbf{f}(x) + \mathbf{J}(x)s,$$

其中  $x, s$  是标量, 且

$$\mathbf{J}(x) = \begin{bmatrix} 1 \\ 2x \end{bmatrix}.$$

代入  $x = 2$ , 得到线性近似为

$$\mathbf{q}(2 + s) = \mathbf{f}(2) + \mathbf{J}(2)s = \begin{bmatrix} -6 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 4 \end{bmatrix} s = \begin{bmatrix} -6 + s \\ 4s \end{bmatrix}.$$

- (b) 设初始点为  $x_0 = 2$ , 根据算法 4.7.2, 现在需要求解线性最小二乘问题

$$\min_s \|\mathbf{q}(s)\|_2^2 = \min_s \underbrace{[(-6 + s)^2 + (4s)^2]}_{:=g(s)}.$$

我们对目标函数  $g(s)$  求导并令其为零

$$g'(s) = 34s - 12 = 0 \implies s = \frac{6}{17}.$$

于是新的估计为

$$x_1 = x_0 + s = 2 + \frac{6}{17} = \frac{40}{17}.$$

**Solution 7.2.** 与上题类似, 本题关注二阶近似的模型. 解答略.

**Solution 7.3.** 代码见 Gitee 仓库.

**Solution 7.4.** 代码见 Gitee 仓库.

**Solution 7.5.** 代码见 Gitee 仓库.

**Solution 7.6.** 代码见 Gitee 仓库.