

数值分析内部课程习题解答

第七章

SCAU DataHub

目录

1	From matrix to insight	2
2	Eigenvalue decomposition	3
3	Singular value decomposition	5
4	Symmetry and definiteness	8
5	Dimension reduction	9

1 From matrix to insight

Solution 1.1. 我们取术语（按行）为 {numerical, analysis, fun}，文档（按列）对应三句：(a) “Numerical analysis is the most fun type of analysis.” (b) “It’s fun to produce numerical values for the digits of pi.” (c) “Complex analysis is a beautiful branch of mathematics.”

逐句统计出现次数（大小写不敏感、精确匹配）得

		(a)	(b)	(c)
$T =$	numerical	1	1	0
	analysis	2	0	1
	fun	1	1	0

这里 (a) 中 “analysis” 出现两次；(b) 中包含 “numerical” 与 “fun”；(c) 只含 “analysis”。

Solution 1.2. 按照 $A_{ij} = 1$ （存在 $i \rightarrow j$ ），图的邻接矩阵为

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}.$$

为核对： $A_{41} = 1$ 对应 $4 \rightarrow 1$ ； $A_{23} = 1$ 对应 $2 \rightarrow 3$ ； $A_{26} = 1$ 对应 $2 \rightarrow 6$ ；其余双向边在矩阵中成对出现，表现为对称。

Solution 1.3. 这是一个对称的矩阵，说明是无向图，考虑起来较容易。

(a) 顶点 5 的相邻顶点数（也称度数）等于第 5 行的 1 的个数：2 个（为顶点 3 与 6）。

(b) 该矩阵关于主对称轴对称，图是无向图。无向图的边数为矩阵中所有 1 的总数的一半。逐行计数得 $3 + 3 + 3 + 1 + 2 + 3 + 1 = 16$ ，故边数为 $16/2 = 8$ 。

(c) 由 (b) 可知为无向图（因为邻接矩阵对称）。

(d) 作图的一种方式只连 $i < j$ 且 $A_{ij} = 1$ 的无向边，得到边集

$$\{(1, 2), (1, 4), (1, 6), (2, 3), (2, 6), (3, 5), (3, 7), (5, 6)\}.$$

Solution 1.4. 代码见 Gitee 仓库。

Solution 1.5. 代码见 Gitee 仓库。

2 Eigenvalue decomposition

Solution 2.1. 诱导范数控制谱半径.

- (a) 设 $A \in \mathbb{C}^{n \times n}$ 有特征值 λ , 对应特征向量 $x \neq 0$, 即 $Ax = \lambda x$. 对任一诱导矩阵范数 $\|\cdot\|$ 都有

$$\|A\| = \sup_{y \neq 0} \frac{\|Ay\|}{\|y\|} \geq \frac{\|Ax\|}{\|x\|} = \frac{\|\lambda x\|}{\|x\|} = |\lambda| \frac{\|x\|}{\|x\|} = |\lambda|.$$

任意诱导范数均满足 $\|A\| \geq |\lambda|$, 结论成立, 换句话说也就是 $\|A\| \geq \rho(A)$ (谱半径).

- (b) 取非正规矩阵

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

其全部特征值都为 1, 故 $\max_{\lambda} |\lambda| = 1$. 对 2-范数, 取 $v = (0, 1)^T$, 则

$$\frac{\|Av\|_2}{\|v\|_2} = \frac{\|(1, 1)^T\|_2}{\|(0, 1)^T\|_2} = \sqrt{2},$$

从而 $\|A\|_2 \geq \sqrt{2} > 1 = |\lambda|$.

Solution 2.2. 教材中 (7. 2. 4) 的矩阵是

$$B = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

其特征多项式为 $(\lambda - 1)^2$, 唯一特征值为 $\lambda = 1$. 解

$$(B - I)v = 0 \Rightarrow \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = 0 \implies v_2 = 0,$$

故特征向量全为 $v = (v_1, 0)^T$ 的数倍, 特征子空间维数为 1, 从而不可能有两条线性无关的特征向量. 也即 B 不可对角化.

Solution 2.3. 代码见 Gitee 仓库.

Solution 2.4. 特殊矩阵的特征值分解.

- (a) 设 $D = \text{diag}(d_1, \dots, d_n)$. 对任意标准基向量 e_i , $De_i = d_i e_i$, 故 d_i 是 D 的特征值, e_i 为对应特征向量. 对角矩阵的特征值就是其对角元.

- (b) 取 3×3 上三角矩阵

$$T = \begin{bmatrix} t_{11} & t_{12} & t_{13} \\ 0 & t_{22} & t_{23} \\ 0 & 0 & t_{33} \end{bmatrix}.$$

首先 $[1, 0, 0]^T$ 显然是 t_{11} 的特征向量. 接着设 $v = [a, 1, 0]^T$, 希望 $(T - t_{22}I)v = 0$. 计算第一分量得 $(t_{11} - t_{22})a + t_{12} = 0$. 若 $t_{11} \neq t_{22}$, 取 $a = -t_{12}/(t_{11} - t_{22})$ 即可得到 t_{22} 的特征向量; 若 $t_{11} = t_{22}$, 则解仍存在 (此时 $t_{12} = 0$ 也成立, 否则与上三角范式矛盾), 于是 $[0, 1, 0]^T$ 就是特征向量. 最后对 t_{33} 类似: 令 $v = [a, b, 1]^T$, 方程 $(T - t_{33}I)v = 0$ 给出

$$\begin{cases} (t_{11} - t_{33})a + t_{12}b + t_{13} = 0, \\ (t_{22} - t_{33})b + t_{23} = 0. \end{cases}$$

当 $t_{22} \neq t_{33}$ 时可先解出 $b = -t_{23}/(t_{22} - t_{33})$, 再代回解 a ; 若 $t_{22} = t_{33}$, 同理由上三角结构可得 $t_{23} = 0$, 此时取 $b = 0$, 再解第一式亦可. 综上, 三角矩阵的特征值为其对角元.

Solution 2.5. (本题答案由 AI 计算) 令

$$A = \frac{\pi}{6} \begin{bmatrix} 4 & 1 \\ 4 & 4 \end{bmatrix}, \quad v_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \lambda_1 = \pi; \quad v_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \quad \lambda_2 = \frac{\pi}{3}.$$

(a) 直接计算 $Av_1 = \pi v_1$, $Av_2 = \frac{\pi}{3}v_2$, 且 v_1, v_2 线性无关, 故 $A = V\Lambda V^{-1}$, 其中

$$V = [v_1 \ v_2] = \begin{bmatrix} 1 & 1 \\ 2 & -2 \end{bmatrix}, \quad V^{-1} = \frac{1}{-4} \begin{bmatrix} -2 & -1 \\ -2 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & \frac{1}{4} \\ \frac{1}{2} & -\frac{1}{4} \end{bmatrix},$$

$\Lambda = \text{diag}(\pi, \pi/3)$, 这给出 A 的特征值分解.

(b) 用多项式函算子 (式 (7. 2. 7)): 若 $p(x) = (x - \pi)^4$, 则

$$p(A) = Vp(\Lambda)V^{-1} = V \begin{bmatrix} 0 & 0 \\ 0 & (\frac{\pi}{3} - \pi)^4 \end{bmatrix} V^{-1} = c v_2 w_2^T,$$

其中 $c = (-\frac{2\pi}{3})^4 = \frac{16\pi^4}{81}$, w_2^T 为 V^{-1} 的第 2 行, 即 $w_2^T = (\frac{1}{2}, -\frac{1}{4})$. 故

$$p(A) = \frac{16\pi^4}{81} \begin{bmatrix} \frac{1}{2} & -\frac{1}{4} \\ -1 & \frac{1}{2} \end{bmatrix}.$$

(c) 函数型 (式 (7. 2. 7) 的函数版本): $\cos(A) = V \cos(\Lambda) V^{-1}$. 由

$$\cos \Lambda = \text{diag}(\cos \pi, \cos \frac{\pi}{3}) = \text{diag}(-1, \frac{1}{2}),$$

写成特征投影之和:

$$\cos(A) = -v_1 w_1^T + \frac{1}{2} v_2 w_2^T = -\begin{bmatrix} \frac{1}{2} & \frac{1}{4} \\ 1 & \frac{1}{2} \end{bmatrix} + \frac{1}{2} \begin{bmatrix} \frac{1}{2} & -\frac{1}{4} \\ -1 & \frac{1}{2} \end{bmatrix} = \begin{bmatrix} -\frac{1}{4} & -\frac{3}{8} \\ -\frac{3}{2} & -\frac{1}{4} \end{bmatrix}.$$

Solution 2.6. 代码见 Gitee 仓库.

Solution 2.7. 代码见 Gitee 仓库.

Solution 2.8. 代码见 Gitee 仓库.

3 Singular value decomposition

Solution 3.1. (本题答案由 AI 计算)

(a)

$$\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix} = \underbrace{\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}}_U \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}}_\Sigma \underbrace{\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}}_{V^T}.$$

U, V 都是正交矩阵, $\Sigma = \text{diag}(1, 0)$ 非负对角, 因而这是一个 SVD (秩为 1). 可取

$$\sigma_1 = 1, \quad u_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad v_1 = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

(奇异向量的符号不唯一, 取负亦可).

(b)

$$\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix} = I_2 \underbrace{\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}}_{\text{不是非负对角}} I_2.$$

中间的矩阵并非非负对角阵 (含 -1), 因此不是 SVD (尽管两端是正交矩阵).

(c) 令 $\alpha = 1/\sqrt{2}$.

$$\begin{bmatrix} 1 & 0 \\ 0 & \sqrt{2} \\ 1 & 0 \end{bmatrix} = \underbrace{\begin{bmatrix} \alpha & 0 & -\alpha \\ 0 & 1 & 0 \\ \alpha & 0 & -\alpha \end{bmatrix}}_{U?} \underbrace{\begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}}_\Sigma \underbrace{\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}}_{V^T}.$$

此处左端因子并非正交: 其第 1、3 列向量平行且内积为 -1 , 也都不是单位长度. 虽然 Σ 非负并与尺寸匹配、 V 正交, 但由于 U 不是正交矩阵, 不是 SVD.

(d) 令 $\alpha = 1/\sqrt{2}$.

$$\begin{bmatrix} \sqrt{2} & \sqrt{2} \\ -1 & 1 \\ 0 & 0 \end{bmatrix} = \underbrace{I_3}_U \underbrace{\begin{bmatrix} 2 & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}}_\Sigma \underbrace{\begin{bmatrix} \alpha & \alpha \\ -\alpha & \alpha \end{bmatrix}}_{V^T}.$$

U 正交, V 的列向量互正交且单位, $\Sigma = \text{diag}(2, \sqrt{2})$ 非负对角, 故为 SVD. 因此

$$\sigma_1 = 2, \quad \sigma_2 = \sqrt{2}, \quad u_1 = e_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad u_2 = e_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix},$$

$$v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Solution 3.2. (本题答案由 AI 计算)

$$A^T A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \Rightarrow \lambda_1 = 3, v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}; \lambda_2 = 1, v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

故奇异值

$$\sigma_1 = \sqrt{3}, \quad \sigma_2 = 1,$$

右奇异向量取 $V = [v_1 \ v_2]$. 左奇异向量由 $u_i = \frac{1}{\sigma_i} A v_i$ 得到:

$$u_1 = \frac{1}{\sqrt{3}} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -2 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{6}} \\ 0 \\ \frac{1}{\sqrt{6}} \\ -\sqrt{\frac{2}{3}} \end{bmatrix}, \quad u_2 = \frac{1}{1} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \\ 0 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \\ 0 \end{bmatrix}.$$

于是 (薄 SVD)

$$A = U \Sigma V^T, \quad U = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ 0 & 0 \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ -\sqrt{\frac{2}{3}} & 0 \end{bmatrix}, \quad \Sigma = \text{diag}(\sqrt{3}, 1), \quad V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

(若需全尺寸 SVD, 可将 U 补成 4×4 的正交矩阵, 将 Σ 补零行.)

Solution 3.3. 代码见 Gitee 仓库.

Solution 3.4. 代码见 Gitee 仓库.

Solution 3.5. 设 $A \in \mathbb{R}^{n \times n}$. 由谱范数的定义

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}, \quad \|A^T\|_2 = \sqrt{\lambda_{\max}(A A^T)}.$$

注意 $A^T A$ 与 $A A^T$ 相似于 Σ^2 (Σ 为 A 的奇异值对角阵), 故二者的特征谱相同, 且 $\lambda_{\max}(A^T A) = \lambda_{\max}(A A^T) = \sigma_1^2$. 于是 $\|A\|_2 = \|A^T\|_2$.

Solution 3.6. 设 $A = U \Sigma V^T$ 为 SVD, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$. Moore–Penrose 伪逆 $A^+ = V \Sigma^+ U^T$, 其中 $\Sigma^+ = \text{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1})$ (对零奇异值置零). 因此

$$\|A^+\|_2 = \|\Sigma^+\|_2 = \sigma_1(\Sigma^+) = \max_j \sigma_j(\Sigma^+) = \frac{1}{\min\{\sigma_j : \sigma_j > 0\}} = \frac{1}{\sigma_r}.$$

结合教材式 (7.3.6) $\|A\|_2 = \sigma_1$, 得

$$\kappa_2(A) = \|A\|_2 \|A^+\|_2 = \frac{\sigma_1}{\sigma_r},$$

即为式 (7.3.7).

Solution 3.7. 给定 $A \in \mathbb{R}^{m \times n}$ ($m > n$) 的 thin SVD: $A = \hat{U} \hat{S} V^T$, 其中 $\hat{U} \in \mathbb{R}^{m \times n}$ 为 ONC、 $\hat{S} = \text{diag}(\sigma_1, \dots, \sigma_n)$. 伪逆 $A^+ = V \hat{S}^{-1} \hat{U}^T$. 于是

$$AA^+ = \hat{U} \hat{S} V^T \cdot V \hat{S}^{-1} \hat{U}^T = \hat{U} \hat{U}^T.$$

右端是投影到 $\text{range}(A)$ 的正交投影矩阵, 故结论成立.

Solution 3.8. 定义 $\kappa_2(A) = \|A\|_2 \|A^+\|_2$. 设 $A = U \Sigma V^T$, 则 $A^T A = V \Sigma^2 V^T$, 故

$$\|A^T A\|_2 = \|\Sigma^2\|_2 = \sigma_1^2, \quad (A^T A)^+ = V \Sigma^{-2} V^T \Rightarrow \|(A^T A)^+\|_2 = \sigma_1^{-2}.$$

于是

$$\kappa_2(A^T A) = \|A^T A\|_2 \|(A^T A)^+\|_2 = \sigma_1^2 \sigma_1^{-2} = \left(\frac{\sigma_1}{\sigma_r}\right)^2 = \kappa_2(A)^2.$$

Solution 3.9. 定理 7.3.5 已给出 $A^* A$ 的非零特征值是 A 的奇异值平方. 对 AA^* 同理: 若 $A = U \Sigma V^*$, 则 $AA^* = U \Sigma^2 U^*$, 其非零特征值亦为 $\{\sigma_j^2\}$. 当 $m > n$ 时, AA^* 额外有 $m - n$ 个零特征值; 当 $m \leq n$ 时, $A^* A$ 有 $n - m$ 个零特征值. 两者的非零谱一致.

Solution 3.10. (本题答案由 AI 计算)

(a) 令 $f(x) = \|Ax\|_2^2 = x^T A^T A x$, 约束 $g(x) = \|x\|_2^2 - 1 = 0$. 拉格朗日函数 $L(x, \lambda) = x^T A^T A x - \lambda(x^T x - 1)$. 驻点满足 $\nabla_x L = 2A^T A x - 2\lambda x = 0$, 即 $A^T A x = \lambda x$, 故极值点是 $A^T A$ 的特征向量.

(b) 由 Rayleigh 商可知最大值为 $\lambda_{\max}(A^T A) = \sigma_1^2$, 从而 $\|A\|_2 = \max_{\|x\|=1} \|Ax\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sigma_1$, 即 (7.3.6).

Solution 3.11. 令

$$C = \begin{bmatrix} 0 & A^* \\ A & 0 \end{bmatrix}, \quad v = \begin{bmatrix} x \\ y \end{bmatrix}.$$

(a) $Cv = \lambda v$ 等价于

$$A^* y = \lambda x, \quad Ay = \lambda y.$$

(b) 消去 y : 由 $A^* y = \lambda x$ 得 $y = \lambda^{-1} A x$ ($\lambda \neq 0$ 时), 代回得 $A^* A x = \lambda^2 x$; 或消去 x 得 $AA^* y = \lambda^2 y$.

(c) 令 $A = U S V^*$, 则 $A^* A = V S^2 V^*$, $AA^* = U S^2 U^*$. 故 (b) 表明 λ^2 必为某个 σ_k^2 , 即 $\lambda = \pm \sigma_k$.

(d) 若 A 非方阵, 则 C 的维数为 $(m+n) \times (m+n)$. 当 $m \neq n$ 时, $A^* A$ (或 AA^*) 存在额外的零特征值, 从 (b) 可见此时 $\lambda = 0$ 也是 C 的可能特征值.

4 Symmetry and definiteness

Solution 4.1. 设给出的分解均为 $A = V\Lambda V^*$, 其中 $\Lambda = \text{diag}(\lambda_i)$ 为实对角矩阵.

- (a) $\Lambda = \text{diag}(-1, 1)$. 一正一负, A 为不定矩阵 (indefinite). 该分解不是 SVD (奇异值需非负). 令 $S = \text{diag}(\text{sign } \lambda_i) = \text{diag}(-1, 1)$, 取

$$U = VS, \quad \Sigma = \text{diag}(|\lambda_i|) = \text{diag}(1, 1),$$

则 $A = U\Sigma V^*$ 为一组 SVD.

- (b) $\Lambda = \text{diag}(5, 0)$. 特征值非负, A 为正半定 (但奇异). 因为 $A \geq 0$ 且 Hermitian, EVD 已经是 SVD: 取 $U = V$, $\Sigma = \Lambda$ 即可.

- (c) $\Lambda = \text{diag}(-2, -8)$ (顺序可换). 全负, A 为负定. 不是 SVD. 取 $S = \text{diag}(-1, -1)$, 令

$$U = VS, \quad \Sigma = \text{diag}(2, 8) \text{ (或排成}(8, 2)\text{)},$$

则 $A = U\Sigma V^*$ 为 SVD.

Solution 4.2. 代码见 Gitee 仓库.

Solution 4.3. 想证明 $R_{A+B}(x) = R_A(x) + R_B(x)$. 定义 Rayleigh 商 $R_M(x) = \frac{x^* M x}{x^* x}$, $x \neq 0$. 则

$$R_{A+B}(x) = \frac{x^*(A+B)x}{x^*x} = \frac{x^*Ax}{x^*x} + \frac{x^*Bx}{x^*x} = R_A(x) + R_B(x).$$

结论对任意同型矩阵 (不必 Hermitian) 成立.

Solution 4.4. 代码见 Gitee 仓库.

Solution 4.5. 给定 $A = \begin{bmatrix} 3 & -2 \\ -2 & 0 \end{bmatrix}$.

- (a) 显式公式:

$$R_A(x) = \frac{x^T A x}{x^T x} = \frac{3x_1^2 - 4x_1x_2}{x_1^2 + x_2^2}, \quad x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \neq 0.$$

- (b) 在 $(x_1, x_2) = (1, 2)$ 处:

$$R_A(1, 2) = \frac{3 - 8}{1 + 4} = -1.$$

- (c) 梯度:

$$\nabla R_A(x) = \frac{2}{x^T x} (Ax - R_A(x)x).$$

注: 关于向量函数求梯度, 设 $f = x^T A x$ (对称 A 下有 $\nabla f = 2Ax$)、 $g = x^T x$ ($\nabla g = 2x$), 将上式看作为 $R_A(x) = (x^T A x)(x^T x)^{-1}$ 即可.

(d) 在 $(1, 2)$ 处的驻点性: $Ax = [3 \cdot 1 - 2 \cdot 2, -2 \cdot 1]^T = [-1, -2]^T$, 且 $R_A(1, 2) = -1$.
故

$$Ax - R_A(x)x = \begin{bmatrix} -1 \\ -2 \end{bmatrix} - (-1) \begin{bmatrix} 1 \\ 2 \end{bmatrix} = 0,$$

从而 $\nabla R_A(1, 2) = 0$.

Solution 4.6. 若 A skew-Hermitian ($A^* = -A$), 我们希望证明 $R_A(x)$ 纯虚. 设 $d = x^*x > 0$, 则

$$\overline{x^*Ax} = (x^*Ax)^* = x^*A^*x = x^*(-A)x = -(x^*Ax),$$

故 (x^*Ax) 为纯虚数或 0. 又 $R_A(x) = n/d$, 分母 d 为正实数, 因此 $R_A(x)$ 是纯虚数.

Solution 4.7. 代码见 Gitee 仓库.

5 Dimension reduction

Solution 5.1. 设 $A \in \mathbb{C}^{n \times n}$ 的奇异值按降序为 $\sigma_1 \geq \dots \geq \sigma_n \geq 0$, SVD 为 $A = U\Sigma V^*$, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$. 令 $E = \sigma_n u_n v_n^*$, 则 $A - E = U \text{diag}(\sigma_1, \dots, \sigma_{n-1}, 0) V^*$ 奇异, 由 Theorem 7.5.1, $\|E\|_2 = \sigma_n$, 且对任意秩 $\leq n-1$ (奇异) 的扰动 B , $\|A - B\|_2 \geq \sigma_n$. 因此 $\text{dist}_2(A, \mathcal{S}) = \sigma_n$.

注: Theorem 7.5.1 的含义是, 把矩阵 A 做 SVD 后, 按奇异值从大到小截断得到 A_k , 它就是离 A 最近的、秩不超过 k 的矩阵. 最近距离正好等于下一条奇异值 σ_{k+1} , 因此误差可由谱直接读出, 既精确又可计算. 这给出了“保留主能量、丢弃小奇异值”的最佳低秩近似原则, 支撑了压缩、去噪、PCA 等降维方法的解释.

Solution 5.2. $A \in \mathbb{C}^{7 \times 4}$, 已知 A^*A 的特征值为 3, 4, 7, 10. 则奇异值为 $\sigma_1 = \sqrt{10}$, $\sigma_2 = \sqrt{7}$, $\sigma_3 = \sqrt{4} = 2$, $\sigma_4 = \sqrt{3}$ (降序排列). 由 Theorem 7.5.1, 2-范数下到秩不超过 k 的最佳逼近误差为 σ_{k+1} .

(a) 到秩-3 矩阵的距离: $\sigma_4 = \sqrt{3}$.

(b) 到秩-2 矩阵的距离: $\sigma_3 = 2$.

Solution 5.3. 代码见 Gitee 仓库.

Solution 5.4. 令 $A = \begin{bmatrix} 1 & b \\ b & 1 \end{bmatrix}$, $b > 0$. 特征分解给出 $\lambda_1 = 1 + b$, $\lambda_2 = 1 - b$, 对应单位特征向量

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad u_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

由于 A 对称 (实 Hermitian), 其 SVD 与特征分解一致, 奇异值为 $\sigma_1 = |1+b| = 1+b$ 、 $\sigma_2 = |1-b|$, 最大奇异向量为 u_1 . 故按 Theorem 7.5.1, 2-范数下最近的秩-1 矩阵为

$$A_1 = \sigma_1 u_1 u_1^T = (1+b) \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = \frac{1+b}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

最优误差为 $\|A - A_1\|_2 = \sigma_2 = |1-b|$.

Solution 5.5. 代码见 Gitee 仓库.